

Klasifikasi Penyakit Pada Pohon Pisang Menggunakan Algoritma CNN

MATA KULIAH KECERDASAN BUATAN



Universitas Telkom

Anggota Kelompok:

Arjun Ahmad Santoso (2311102211)

Buswirawan Raditya Boenyamin (2311102090)

Willyan Hyuga Pratama (2211102129)

Dosen: Dasril Aldo, S.Kom., M.Kom.

Program Studi Sarjana Teknik Informatika

Fakultas Informatika

Universitas Telkom

Purwokerto

2025

DAFTAR ISI

1. PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan	2
2. METODE PENGEMBANGAN / TAHAPAN PENELITIAN	3
2.1 Algoritma <i>Convolutional Neural Network (CNN)</i>	3
2.1.1. Cara Kerja Metode	3
2.1.2. Alasan Pemilihan Metode	3
3. HASIL ANALISA	7
3.1 Analisis Data.....	7
3.2 Hasil Evaluasi Model.....	7
3.3 Interpretasi Hasil dan Pembahasan	9
3.4 Kelebihan dan Kekurangan Metode Berdasarkan Eksperimen.....	10
4. PERANCANGAN UI DAN ALUR SISTEM.....	10
4.1 Alur Sistem (System Flow / User Flow)	10
4.2 Wireframe / Mockup Desain UI	11
4.3 Penjelasan Konsep UI.....	13
5. KESIMPULAN.....	13
5.1 Pencapaian Utama Proyek AI	14
5.2 Jawaban atas Rumusan Masalah.....	14
5.3 Efektivitas Metode AI yang Digunakan.....	14
5.4 Saran untuk Pengembangan Selanjutnya.....	15

DAFTAR TABEL

Tabel 1 Evaluasi Model	8
------------------------------	---

DAFTAR GAMBAR

Gambar 1 Hasil Evaluasi Model	8
Gambar 2 Alur Sistem	11
Gambar 3 Rancangan Wireframe Aplikasi	12
Gambar 4 Desain UI Aplikasi.....	13

1. PENDAHULUAN

1.1 Latar Belakang

Tanaman pisang merupakan salah satu komoditas penting di Indonesia yang banyak dibudidayakan dan menjadi sumber mata pencaharian bagi sebagian besar petani. Namun, produktivitas tanaman pisang sering mengalami penurunan akibat serangan berbagai jenis penyakit daun seperti Black Sigatoka, Yellow Sigatoka, Panama Disease, dan penyakit lainnya. Gejala yang muncul pada daun sering kali memiliki kemiripan antar penyakit sehingga menyulitkan proses identifikasi apabila hanya mengandalkan pengamatan visual. Kesalahan diagnosis dapat menyebabkan penanganan yang tidak tepat, memperburuk kondisi tanaman, dan berdampak pada kerugian ekonomi bagi petani.

Seiring berkembangnya teknologi digital, pengolahan citra menjadi salah satu metode yang dapat dimanfaatkan untuk membantu proses identifikasi penyakit tanaman. Dengan memanfaatkan citra daun sebagai sumber informasi visual, sebuah sistem dapat dilatih untuk mengenali pola-pola tertentu seperti perubahan warna, tekstur, bentuk bercak, dan karakteristik lain yang menggambarkan kondisi penyakit. Hal ini membuka peluang untuk menciptakan solusi otomatis yang lebih cepat, objektif, dan konsisten dibandingkan metode identifikasi manual.

Dalam bidang Kecerdasan Buatan, salah satu algoritma yang paling efektif untuk menangani permasalahan klasifikasi citra adalah Convolutional Neural Network (CNN). CNN mampu mengekstraksi fitur visual secara langsung dari gambar melalui proses convolution dan pooling, sehingga model dapat mempelajari perbedaan pola pada setiap kelas penyakit tanpa memerlukan proses ekstraksi fitur secara manual. Keunggulan CNN dalam mengenali pola visual menjadikannya sangat relevan untuk digunakan dalam sistem klasifikasi penyakit daun pisang.

Melalui penerapan CNN, sistem diharapkan mampu memberikan prediksi penyakit secara otomatis berdasarkan citra daun yang diinputkan, sehingga dapat membantu petani, peneliti, maupun pihak terkait dalam mengambil tindakan yang lebih cepat dan akurat. Dengan demikian, penggunaan AI melalui pendekatan CNN tidak hanya relevan dengan kebutuhan modernisasi sektor pertanian, tetapi juga memberikan kontribusi nyata dalam memanfaatkan teknologi untuk menyelesaikan permasalahan di dunia nyata.

1.2 Rumusan Masalah

1. Bagaimana mengatasi kendala identifikasi penyakit daun pisang (seperti *Black Sigatoka*, *Yellow Sigatoka*, dan *Panama Disease*) yang memiliki kemiripan gejala visual, di mana pengamatan manual sering kali bersifat subjektif dan rentan terhadap kesalahan diagnosis?
2. Bagaimana merancang sebuah sistem berbasis pengolahan citra digital yang mampu mengenali pola visual penyakit daun pisang secara otomatis untuk membantu petani melakukan deteksi yang lebih cepat dan objektif?
3. Bagaimana kinerja algoritma *Convolutional Neural Network* (CNN) dalam melakukan klasifikasi penyakit daun pisang berdasarkan ekstraksi fitur otomatis (seperti tekstur dan bentuk bercak) dari citra daun?

1.3 Tujuan

Tujuan Umum

Mengembangkan sistem klasifikasi otomatis berbasis pengolahan citra digital menggunakan algoritma *Convolutional Neural Network* (CNN) untuk membantu identifikasi penyakit daun pisang secara cepat, objektif, dan akurat, sehingga dapat meminimalkan kerugian ekonomi akibat kesalahan diagnosis manual.

Tujuan Khusus

Secara spesifik, penelitian ini bertujuan untuk:

1. Menerapkan Arsitektur CNN: Merancang dan melatih model *Convolutional Neural Network* (CNN) agar mampu mengekstraksi fitur visual (seperti pola bercak, tekstur, dan warna) secara otomatis dari citra daun pisang.
2. Mengklasifikasikan Penyakit: Menguji kemampuan model dalam membedakan dan mengklasifikasikan jenis penyakit daun pisang yang memiliki kemiripan gejala, yaitu *Black Sigatoka*, *Yellow Sigatoka*, dan *Panama Disease*.
3. Mengevaluasi Kinerja Model: Mengukur tingkat performa model yang dibangun berdasarkan parameter akurasi, presisi, *recall*, dan *f1-score* untuk memastikan validitas sistem sebelum diterapkan.

2. METODE PENGEMBANGAN / TAHAPAN PENELITIAN

2.1 Algoritma *Convolutional Neural Network* (CNN)

Dalam penelitian ini, metode yang digunakan untuk menyelesaikan permasalahan klasifikasi penyakit daun pisang adalah *Convolutional Neural Network* (CNN). CNN merupakan salah satu jenis algoritma *Deep Learning* yang merupakan pengembangan dari *Artificial Neural Network* (ANN), yang didesain secara spesifik untuk memproses data yang memiliki struktur grid, seperti data citra digital (gambar).

2.1.1. Cara Kerja Metode

Secara prinsip, cara kerja CNN terinspirasi oleh cara kerja korteks visual pada otak manusia dalam mengenali objek. Berbeda dengan jaringan saraf biasa yang meratakan input gambar menjadi satu vektor panjang, CNN mempertahankan struktur spasial gambar. Arsitektur CNN umumnya terdiri dari tiga jenis lapisan utama:

1. Convolutional Layer (Lapisan Konvolusi): Merupakan lapisan inti dari CNN. Pada tahap ini, dilakukan proses ekstraksi fitur menggunakan *filter* atau *kernel* yang bergeser ke seluruh bagian gambar. Proses ini menghasilkan *feature map* yang mendeteksi pola-pola visual seperti garis, tepi, warna, dan tekstur daun.
2. Pooling Layer (Subsampling): Lapisan ini berfungsi untuk mereduksi dimensi dari *feature map* (down-sampling) tanpa menghilangkan informasi penting. Hal ini bertujuan untuk mengurangi beban komputasi dan menghindari *overfitting*. Teknik yang paling umum digunakan adalah *Max Pooling* (mengambil nilai terbesar dari area tertentu).
3. Fully Connected Layer: Setelah melalui beberapa proses konvolusi dan pooling, data diratakan (*flatten*) menjadi vektor satu dimensi dan dimasukkan ke dalam jaringan saraf tiruan biasa untuk melakukan klasifikasi akhir (misalnya: menentukan apakah daun terkena *Black Sigatoka* atau sehat).

2.1.2. Alasan Pemilihan Metode

Algoritma *Convolutional Neural Network* (CNN) dipilih dalam tugas ini karena beberapa alasan utama:

1. Ekstraksi Fitur Otomatis: Kelebihan utama CNN adalah kemampuannya mempelajari ciri-ciri penting pada gambar (seperti bentuk bercak atau warna daun) secara otomatis. Kita tidak perlu melakukan proses ekstraksi fitur yang rumit secara manual, sehingga proses pembuatan model menjadi lebih efisien.
2. Sangat Cocok untuk Data Gambar: CNN dirancang khusus untuk memahami pola visual. Karena penyakit daun pisang dibedakan berdasarkan pola tekstur dan perubahan warna pada daun, arsitektur CNN sangat efektif untuk mengenali perbedaan detail antar penyakit tersebut.
3. Akurasi yang Tinggi: Saat ini, CNN merupakan metode yang paling standar dan terbukti memberikan hasil akurasi terbaik untuk kasus klasifikasi gambar dibanding metode *machine learning* biasa, terutama ketika data gambar yang digunakan cukup bervariasi.

2.2 Tahapan Penelitian / Pengembangan Sistem

Untuk mencapai tujuan penelitian yang telah dirumuskan, proses pengembangan sistem dilakukan melalui tujuh tahapan sistematis sebagai berikut.

1. Pengumpulan Data

Tahap awal penelitian dimulai dengan mengumpulkan dataset citra daun pisang. Data yang digunakan bersumber dari repositori publik (Kaggle) yang menyediakan kumpulan gambar daun pisang dalam berbagai kondisi. Dataset ini dikelompokkan ke dalam empat kelas kategori sesuai dengan fokus penelitian, yaitu:

- Black Sigatoka: Citra daun dengan gejala bercak garis gelap.
- Yellow Sigatoka: Citra daun dengan gejala bercak kuning meluas.
- Panama Disease: Citra daun yang menunjukkan gejala layu fusarium.
- Healthy: Citra daun pisang yang sehat sebagai pembanding. Jumlah total citra dipastikan cukup untuk merepresentasikan variasi visual dari setiap penyakit agar model dapat belajar dengan baik.

2. Pra-Pemrosesan Data

Data citra mentah seringkali memiliki ukuran dan pencahayaan yang beragam. Oleh karena itu, dilakukan pra-pemrosesan agar data siap dilatih oleh algoritma CNN:

- Resizing: Menyeragamkan ukuran resolusi seluruh gambar (misalnya menjadi 128 x 128 piksel atau 224 x 224 piksel) untuk menyesuaikan dengan *input layer* model.
- Normalisasi: Mengubah nilai piksel dari rentang 0–255 menjadi 0–1 untuk mempercepat proses komputasi.
- Augmentasi Data: Melakukan manipulasi gambar secara acak (seperti rotasi, *zoom*, atau *flip*) pada data latih untuk memperbanyak variasi data dan mencegah model menghafal data (*overfitting*).
- Pembagian Data: Memecah dataset menjadi data latih (*training set*) dan data uji (*testing set*) dengan rasio tertentu (misalnya 80:20).

3. Pemilihan Fitur

Berbeda dengan metode *machine learning* konvensional di mana fitur dipilih secara manual, pada penelitian ini pemilihan fitur dilakukan secara otomatis oleh arsitektur CNN yang dirancang. Tahap ini berfokus pada perancangan lapisan konvolusi (*convolutional layers*) yang bertugas menyaring dan menyeleksi fitur visual penting. Model akan diposisikan untuk mempelajari fitur hirarkis, mulai dari fitur sederhana seperti garis dan tepi daun, hingga fitur kompleks seperti tekstur bercak penyakit yang spesifik.

4. Pelatihan Model

Pada tahap ini, data latih dimasukkan ke dalam model CNN untuk diproses. Proses pelatihan melibatkan pembelajaran iteratif (*epochs*) di mana model akan terus memperbarui bobot-bobot filternya. Algoritma optimasi (seperti *Adam* atau *SGD*) digunakan untuk meminimalkan nilai *loss function*, sehingga model semakin pintar dalam mengenali pola penyakit dari waktu ke waktu.

5. Evaluasi Model

Selama proses pelatihan berlangsung, kinerja model dipantau menggunakan data validasi. Evaluasi ini bertujuan untuk melihat grafik pergerakan akurasi dan *loss*. Tahap ini krusial untuk mendeteksi dini apakah terjadi *overfitting* (model jago di latihan tapi gagal di tes) atau *underfitting* (model gagal mengenali pola), sehingga parameter model dapat disesuaikan kembali jika diperlukan.

6. Pengujian Akhir

Setelah model selesai dilatih dan dianggap optimal, dilakukan pengujian akhir menggunakan data uji (*test set*), yaitu sekumpulan gambar baru yang belum pernah dilihat

model sebelumnya. Tahap ini mensimulasikan kinerja sistem di dunia nyata untuk memprediksi jenis penyakit pada daun pisang secara objektif.

7. Analisis Hasil

Tahap terakhir adalah menganalisis performa sistem berdasarkan hasil pengujian. Analisis dilakukan dengan menghitung metrik evaluasi seperti:

- Akurasi: Tingkat keberhasilan model secara keseluruhan.
- Confusion Matrix: Tabel untuk melihat detail kesalahan prediksi (misalnya: apakah penyakit *Black Sigatoka* sering tertukar dengan *Yellow Sigatoka*).
- Presisi dan Recall: Untuk mengukur kehandalan model pada setiap kelas penyakit. Hasil analisis ini akan menjadi kesimpulan apakah sistem yang dibangun sudah layak dan efektif untuk membantu petani dalam mengidentifikasi penyakit tanaman pisang.

3. HASIL ANALISA

3.1 Analisis Data

Dataset yang digunakan dalam penelitian ini bertujuan untuk mengklasifikasikan kondisi daun pisang ke dalam 7 kelas kategori yang berbeda. Data mencakup berbagai kondisi penyakit serta daun sehat. Berdasarkan laporan klasifikasi, dataset terbagi ke dalam kelas-kelas berikut:

1. Banana Black Sigatoka Disease
2. Banana Bract Mosaic Virus Disease
3. Banana Healthy Leaf (Daun Sehat)
4. Banana Insect Pest Disease (Serangan Hama)
5. Banana Moko Disease
6. Banana Panama Disease
7. Banana Yellow Sigatoka Disease

Data uji (*test set*) yang digunakan untuk evaluasi berjumlah **652 sampel citra**. Sebelum dimasukkan ke dalam model, data telah melalui proses *preprocessing* berupa *rescaling* (normalisasi piksel 1./255) dan *resizing* untuk menyeragamkan dimensi input agar sesuai dengan arsitektur CNN.

3.2 Hasil Evaluasi Model

Evaluasi dilakukan menggunakan metrik utama klasifikasi yaitu Akurasi, Presisi, *Recall*, dan *F1-Score*. Berdasarkan pengujian pada data validasi, diperoleh hasil performa model sebagai berikut:

```

... 21/21 ----- 6s 263ms/step
Accuracy : 0.7791
Precision: 0.7946
Recall   : 0.7791
F1-Score : 0.7710

Classification Report:
precision    recall  f1-score   support
Banana Black Sigatoka Disease      0.78      0.48      0.59      113
Banana Bract Mosaic Virus Disease  0.80      0.65      0.72       75
    Banana Healthy Leaf            0.90      0.99      0.94     132
    Banana Insect Pest Disease    0.66      0.90      0.76     140
    Banana Moko Disease          0.71      0.90      0.80      78
    Banana Panama Disease        0.90      0.67      0.76      78
Banana Yellow Sigatoka Disease    0.93      0.72      0.81      36

accuracy                           0.78      0.78      0.78      652
macro avg                          0.81      0.76      0.77      652
weighted avg                       0.79      0.78      0.77      652

```

Gambar 1 Hasil Evaluasi Model

1. **Metrik Performa Keseluruhan** Tabel berikut merangkum hasil evaluasi model secara global (*Weighted Average*):

Metrik	Nilai Rata-rata (Weighted Avg)	Keterangan
Akurasi	77.91%	Model mampu memprediksi dengan benar sekitar 78 dari 100 citra.
Presisi	79.46%	Dari semua prediksi positif, 79% di antaranya benar-benar relevan.
Recall	77.91%	Model mampu menemukan kembali 78% data yang relevan dari total data asli.
F1-Score	77.10%	Rata-rata harmonik yang menunjukkan keseimbangan antara presisi dan recall.

Tabel 1 Evaluasi Model

2. **Performa Per Kelas (Classification Report)** Rincian performa untuk setiap jenis penyakit adalah sebagai berikut:

- **Performa Terbaik:** Dicapai pada kelas Banana Healthy Leaf dengan nilai *F1-Score* sebesar 0.94, *Precision* 0.90, dan *Recall* 0.99. Hal ini menunjukkan model sangat handal dalam mengenali daun yang sehat.
- **Performa Terendah (Recall):** Terjadi pada kelas Banana Black Sigatoka Disease dengan nilai *Recall* hanya 0.48. Artinya, model sering gagal mendeteksi penyakit ini (banyak *False Negative*).
- **Performa Terendah (Precision):** Terjadi pada kelas Banana Insect Pest Disease dengan nilai 0.66, yang mengindikasikan model cukup sering salah memprediksi kelas lain sebagai serangan hama (*False Positive*).

3.3 Interpretasi Hasil dan Pembahasan

Berdasarkan hasil eksperimen di atas, dapat diinterpretasikan beberapa hal mengenai kinerja model CNN yang dibangun:

1. Kemampuan Deteksi Daun Sehat vs Penyakit: Model memiliki kemampuan yang sangat baik dalam membedakan daun sehat (Healthy Leaf) dengan daun berpenyakit, dibuktikan dengan Recall yang nyaris sempurna (0.99). Fitur visual daun sehat (hijau bersih) lebih mudah dipelajari oleh model dibandingkan pola bercak penyakit yang kompleks.
2. Kendala pada Penyakit Sigatoka: Terdapat ketimpangan performa pada varian penyakit Sigatoka.
 - Yellow Sigatoka terdeteksi cukup baik (*Precision* 0.93).
 - Black Sigatoka memiliki Recall rendah (0.48). Hal ini kemungkinan disebabkan oleh kemiripan visual yang tinggi antara Black Sigatoka dengan tahap awal penyakit lain atau Insect Pest, sehingga model kesulitan membedakannya secara spesifik.
3. Sensitivitas terhadap Hama (Insect Pest): Model sangat sensitif mendeteksi serangan hama (Recall 0.90), namun tingkat kepastiannya rendah (*Precision* 0.66). Ini berarti model cenderung "terlalu agresif" dalam memprediksi hama, sehingga beberapa kerusakan daun akibat penyakit lain mungkin salah diklasifikasikan sebagai serangan hama.
4. Keseimbangan Model: Secara umum, model memiliki tingkat akurasi menengah ke atas (78%). Meskipun belum mencapai akurasi >90%, model sudah cukup efektif untuk

memilah mayoritas penyakit, terutama untuk Panama Disease dan Moko Disease yang memiliki performa seimbang.

3.4 Kelebihan dan Kekurangan Metode Berdasarkan Eksperimen

Kelebihan:

- Identifikasi Daun Sehat yang Sangat Akurat: Model sangat dapat diandalkan untuk menyaring tanaman yang sehat, sehingga petani dapat fokus hanya pada tanaman yang terdeteksi sakit.
- Multi-Class Classification: Metode ini mampu membedakan 7 kategori sekaligus, tidak hanya sekedar "Sakit" atau "Sehat", namun memberikan diagnosa spesifik jenis penyakitnya.
- Deteksi Dini Hama: Tingginya *recall* pada *Insect Pest* dan *Moko Disease* (0.90) menunjukkan model jarang melewatkannya kasus serangan hama dan penyakit Moko.

Kekurangan:

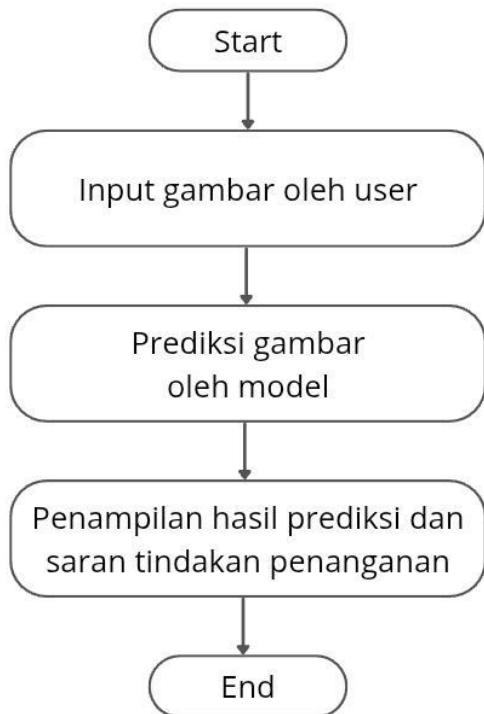
- Rendahnya Deteksi Black Sigatoka: *Recall* 48% pada *Black Sigatoka* adalah kelemahan utama. Model melewatkannya lebih dari setengah kasus penyakit ini, yang berisiko jika diterapkan di lapangan tanpa verifikasi manual.
- False Positive pada Hama: Presisi yang rendah pada *Insect Pest* dapat menyebabkan alarm palsu, di mana petani mungkin mengira tanaman terserang hama padahal sebenarnya mengalami penyakit lain.
- Bias Data: Perbedaan jumlah *support* data (contoh: *Healthy* 132 data vs *Yellow Sigatoka* 36 data) mempengaruhi kestabilan model, di mana kelas dengan data lebih sedikit cenderung memiliki variansi performa yang lebih tinggi.

4. PERANCANGAN UI DAN ALUR SISTEM

4.1 Alur Sistem (System Flow / User Flow)

Aplikasi/sistem ini dirancang untuk memprediksi penyakit pada tanaman pisang berdasarkan gambar daun pisang yang diinputkan oleh pengguna (user) menggunakan model

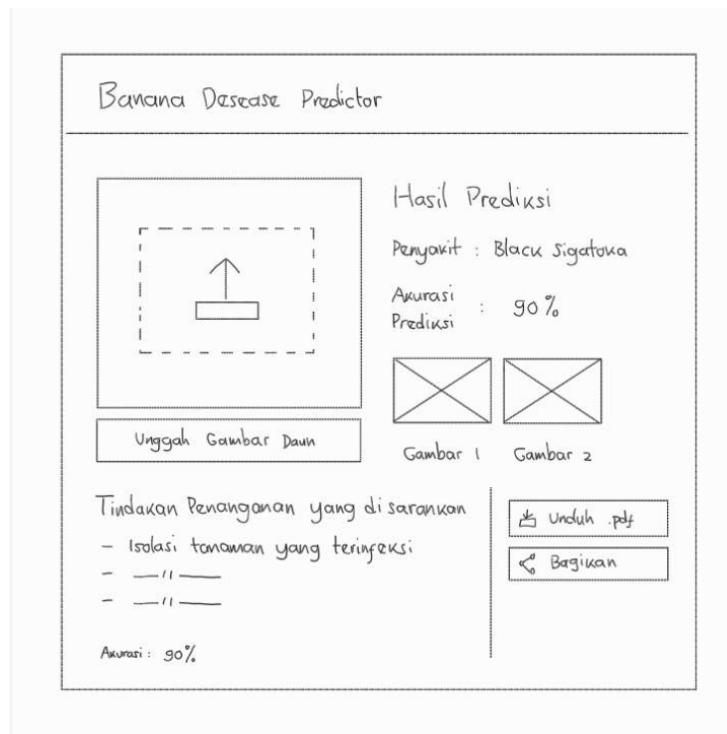
machine learning berbasis Neural Network. Sistem juga dirancang untuk memberikan saran penanganan berdasarkan penyakit yang terdeteksi. Dengan adanya sistem ini, pengguna dapat mengetahui penyakit dan tindakan penanganan sehingga kerugian yang ditimbulkan dapat diminimalisir. Alur penggunaan sistem oleh pengguna diilustrasikan pada Gambar 2.



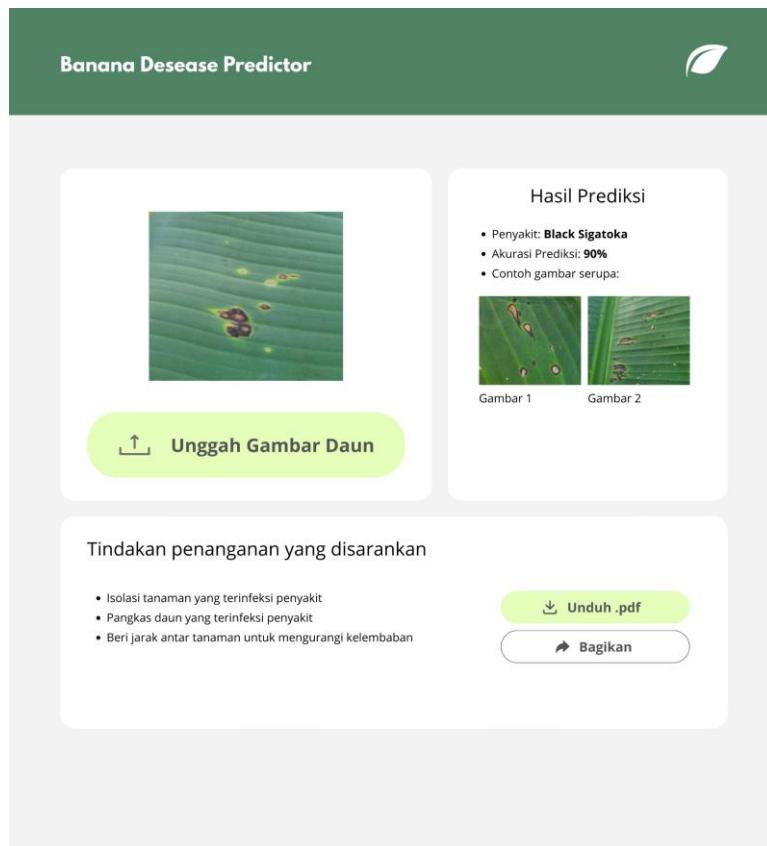
Gambar 2 Alur Sistem

4.2 Wireframe / Mockup Desain UI

Berikut ini adalah rancangan wireframe (low-fidelity UI) (Gambar 3) dan desain UI (Gambar 4) dari aplikasi yang dirancang, yang merupakan single-page yang memuat input dan output (hasil prediksi).



Gambar 3 Rancangan Wireframe Aplikasi



Gambar 4 Desain UI Aplikasi

4.3 Penjelasan Konsep UI

Aplikasi/Sistem dibuat menggunakan antarmuka dengan desain minimalis single-page untuk memudahkan pengguna dalam mengidentifikasi komponen UI dan fungsinya. Warna yang dipilih berupa hijau untuk menggambarkan kesegaran serta ketenangan dalam mengambil keputusan. Font yang digunakan merupakan font sans. Ini dilakukan untuk meningkatkan keterbacaan pada desain.

5. KESIMPULAN

Berdasarkan penelitian dan eksperimen yang telah dilakukan dalam pembangunan sistem klasifikasi penyakit pada pohon pisang menggunakan algoritma *Convolutional Neural Network* (CNN), dapat ditarik beberapa kesimpulan sebagai berikut:

5.1 Pencapaian Utama Proyek AI

Penelitian ini berhasil mengembangkan model *Deep Learning* yang mampu mengklasifikasikan citra daun pisang ke dalam 7 kategori berbeda, yaitu: *Black Sigatoka*, *Bract Mosaic Virus*, *Insect Pest*, *Moko Disease*, *Panama Disease*, *Yellow Sigatoka*, dan *Healthy Leaf*. Model yang dibangun telah melewati proses pelatihan dan validasi menggunakan *Banana Disease Recognition Dataset*, menghasilkan sebuah sistem yang dapat menerima input gambar daun dan mengeluarkan prediksi jenis penyakit secara otomatis.

5.2 Jawaban atas Rumusan Masalah

Sistem ini menjawab permasalahan utama mengenai sulitnya identifikasi penyakit pisang secara visual manual yang sering kali memiliki gejala serupa.

- Identifikasi Otomatis: Algoritma CNN terbukti mampu membedakan pola visual penyakit yang kompleks pada daun pisang tanpa memerlukan ekstraksi fitur manual.
- Solusi bagi Petani: Dengan kemampuan membedakan daun sehat dan sakit secara akurat, sistem ini berpotensi menjadi alat bantu diagnosa dini bagi petani untuk mencegah penyebaran penyakit lebih luas, sesuai dengan latar belakang masalah mengenai risiko kerugian ekonomi akibat kesalahan diagnosis.

5.3 Efektivitas Metode AI yang Digunakan

Metode CNN yang diterapkan menunjukkan tingkat efektivitas yang cukup baik (Moderate) dengan rincian sebagai berikut:

- Akurasi Global: Model mencapai tingkat akurasi sebesar 77.91% pada data uji.
- Deteksi Tanaman Sehat: Metode ini sangat efektif dalam menyaring tanaman sehat, dibuktikan dengan nilai *Recall* sebesar 99% dan *F1-Score* 94% pada kelas *Healthy Leaf*.
- Keterbatasan Spesifik: Meskipun efektif secara umum, metode ini masih memiliki kelemahan dalam membedakan varian penyakit yang sangat mirip secara visual, khususnya pada penyakit *Black Sigatoka* yang memiliki tingkat deteksi (*Recall*) terendah (48%), serta adanya bias prediksi pada kelas *Insect Pest*.

5.4 Saran untuk Pengembangan Selanjutnya

Untuk meningkatkan performa dan kegunaan sistem di masa mendatang, disarankan beberapa perbaikan berikut:

1. Penyeimbangan Data (Data Balancing): Melakukan augmentasi data lebih lanjut atau menambah sampel pada kelas dengan jumlah data sedikit (seperti *Yellow Sigatoka* dan *Panama Disease*) agar model tidak bias terhadap kelas mayoritas.
2. Penerapan Transfer Learning: Menggunakan arsitektur model yang lebih canggih dan telah dilatih sebelumnya (*pre-trained models*) seperti MobileNetV2, ResNet, atau VGG16. Arsitektur ini umumnya memiliki kemampuan ekstraksi fitur yang lebih detail dibanding model CNN sederhana (Sequential) yang digunakan saat ini, sehingga berpotensi meningkatkan akurasi di atas 90%.
3. Pengembangan Aplikasi Mobile: Mengintegrasikan model yang telah dilatih ke dalam aplikasi berbasis Android/iOS menggunakan TensorFlow Lite, sehingga petani dapat memotret daun langsung di kebun dan mendapatkan hasil diagnosa secara *real-time* tanpa koneksi internet berat.
4. Optimasi Hyperparameter: Melakukan eksperimen lebih lanjut pada pengaturan *learning rate*, jumlah *epoch*, dan *batch size* untuk mengurangi nilai *loss* dan meningkatkan presisi pada kelas-kelas yang masih sering salah terdeteksi.